

Classification Automatique des Leucocytes par Apprentissage Profond

Une Analyse Itérative des Architectures, de la Régularisation
et de la Gestion du Déséquilibre de Classes

Rapport de Challenge – IMA205
Télécom Paris, 2026, DIONNET ELIOTT

Cours : IMA205 – Analyse d’images médicales
Classes : 13 types de globules blancs

April 19, 2026

Abstract

L’identification automatique des globules blancs (leucocytes) à partir d’images microscopiques de frottis sanguins est un enjeu majeur pour le diagnostic automatisé des pathologies hématologiques. Ce rapport retrace une démarche expérimentale complète visant à concevoir un modèle de classification robuste sur 13 sous-classes de cellules sanguines dans le cadre du challenge IMA205. Partant d’une ligne de base classique (Random Forest, 16% de précision), nous progressons vers des approches par apprentissage profond avec transfer learning. De multiples stratégies ont été éprouvées et analysées critiquement : l’augmentation de la capacité avec EfficientNet-B4 conduisant au sur-apprentissage, l’utilisation des poids IMAGENET1K_V2 sur ResNet50, et plusieurs stratégies de gestion du déséquilibre extrême des classes. Notre conclusion principale est qu’une architecture classique et bien dimensionnée (ResNet50), couplée à un prétraitement intelligent, à une stratégie d’entraînement en deux phases et à une régularisation stricte, offre le meilleur compromis entre apprentissage des caractéristiques et généralisation, atteignant **71% de précision** en validation.

1 Introduction et Contexte

La classification automatique des leucocytes (globules blancs) est un problème fondamental en hématologie computationnelle. En pratique clinique, l’identification manuelle des différents types de leucocytes au microscope est une tâche longue, coûteuse et sujette à la variabilité inter-observateur. Un système de classification automatique permettrait d’accélérer significativement le diagnostic de pathologies telles que les leucémies, les infections bactériennes ou virales, et les troubles auto-immuns.

Traditionnellement, le comptage et l’analyse s’effectuent via deux protocoles : la Numération Formule Sanguine (NFS ou CBC) et le comptage différentiel (DBC). Si les analyseurs automatiques (comme la cytométrie en flux) permettent de compter les cellules quantitativement, ils manquent de la précision qualitative nécessaire pour identifier visuellement les variations morphologiques subtiles. Ainsi, le comptage différentiel manuel reste très utilisé, bien qu’il présente des limites majeures : il est chronophage, fastidieux pour les experts, et sujet aux erreurs d’échantillonnage.

Dans le cadre du challenge IMA205, le jeu de données comprend des images microscopiques annotées en 13 classes correspondant à différents sous-types de leucocytes : BA (basophiles), BL (blastés), BNE (neutrophiles en bande), EO (éosinophiles), LY (lymphocytes), MMY (métamyélocytes), MO (monocytes), MY (myélocytes), PC (plasmocytes), PLY (prolymphocytes), PMY (promyélocytes), SNE (neutrophiles segmentés) et VLY (lymphocytes variants).

Ce rapport présente une approche itérative par apprentissage profond. Plutôt que de présenter uniquement le modèle final optimisé, cette étude propose une analyse critique de l’ensemble de la démarche expérimentale, justifiant les succès et expliquant les échecs face à la complexité des données médicales.

Notre démarche suit une progression méthodologique naturelle, résumée dans le tableau 1 : nous débutons par des approches classiques basées sur des features morphologiques manuelles couplées à des forêts aléatoires, avant de passer à des architectures de réseaux de neurones convolutifs en transfer learning. Cette progression nous a permis de comprendre les forces et limites de chaque paradigme, et de justifier nos choix architecturaux successifs.

Table 1: Progression méthodologique de l’étude

Étape	Approche	Val. Acc.
1	Random Forest (features manuelles)	16%
2	MobileNet (transfer learning)	35%
3	ResNet50 Phase 1 (tête seule)	60%
4	ResNet50 Phase 2 (fine-tuning)	71%

2 État de l'Art

2.1 Approches Classiques : Morphologie Mathématique

Avant l'avènement massif des réseaux de neurones convolutifs (CNN), l'état de l'art s'appuyait sur des pipelines de traitement d'image complexes. La première étape consistait à isoler le leucocyte des érythrocytes et du plasma via des algorithmes de seuillage. La méthode d'Otsu, par exemple, sépare l'avant-plan de l'arrière-plan en minimisant la variance intra-classe :

$$\sigma_W^2(t) = w_0(t)\sigma_0^2(t) + w_1(t)\sigma_1^2(t) \quad (1)$$

où w_0 et w_1 sont les proportions de pixels des deux classes séparées par le seuil t , et σ_0^2 , σ_1^2 leurs variances respectives. Des opérations de morphologie mathématique (érosion, dilatation, ouverture, fermeture) étaient ensuite appliquées pour éliminer les artefacts et lisser les contours des noyaux. Ces caractéristiques (aire, périmètre, excentricité, circularité) nourrissaient des classifieurs statistiques tels que les Séparateurs à Vaste Marge (SVM) ou les réseaux bayésiens.

2.2 L'essor du Deep Learning

Récemment, l'apprentissage profond a supplanté ces méthodes. Des architectures pré-entraînées comme ResNet [3], VGG ou Inception sont utilisées pour extraire automatiquement les caractéristiques (Transfer Learning). Ces approches atteignent des performances bien supérieures sur des datasets de grande taille. Cependant, le Deep Learning en hématologie présente des failles spécifiques. Ces algorithmes nécessitent des volumes de données importants pour ne pas sur-apprendre. De plus, ils fonctionnent comme des "boîtes noires". En l'absence d'une segmentation stricte en amont, un réseau convolutif puissant risque d'apprendre le bruit ambiant (couleur du fond d'un laboratoire, présence de globules rouges) plutôt que la structure interne du noyau. Ce risque est décuplé lorsque le jeu de données présente un fort déséquilibre de classes.

2.3 Défis Inhérents à l'Imagerie Microscopique

Sur la base de la littérature, neuf défis majeurs ont été identifiés pour la classification automatisée de leucocytes :

1. **Coloration (Staining)** : L'utilisation de processus chimiques différents (Giemsa, Wright, May-Grünwald-Giemsa) modifie drastiquement la couleur et le contraste du cytoplasme.
2. **Illumination** : L'intensité lumineuse des microscopes n'est pas standardisée entre les laboratoires.
3. **Stades de maturation** : Les légères différences inter-classes (ex : neutrophile *Band* vs. *Segmented*) rendent les frontières de décision presque arbitraires.
4. **Taille et localisation** : Le ratio noyau/cytoplasme varie fortement selon le type et le stade cellulaire.

5. **Rotation** : Les cellules sont photographiées sous des angles arbitraires.
6. **Complexité structurelle intraclasse** : Grande variabilité morphologique au sein d'une même classe.
7. **Bruit et fond** : Présence de plasma, d'hématies et de plaquettes parasites dans le champ de vision.
8. **Qualité numérique** : Résolution et bruit des caméras de microscope varient selon l'équipement.
9. **Déséquilibre extrême des données** : Point critique détaillé dans la section suivante.

2.4 Justification du Transfer Learning

Le paradigme du transfer learning repose sur l'hypothèse que les représentations apprises sur un grand jeu de données généraliste (ImageNet, 1,4 million d'images, 1 000 classes) sont suffisamment génériques pour être réutilisées dans un domaine cible. Pour les images cellulaires, cette hypothèse est partiellement vérifiée : les premières couches d'un ResNet50 pré-entraîné détectent effectivement des bords, des gradients et des textures qui se retrouvent dans les images de frottis sanguins (granularité de la chromatine, contour du noyau). Les couches profondes, en revanche, encodent des concepts sémantiques spécifiques aux objets naturels et bénéficient d'un fine-tuning pour s'adapter aux structures microscopiques.

L'entraînement d'un réseau "from scratch" a été brièvement exploré mais abandonné rapidement : sans pré-entraînement, le modèle peine à converger sur un jeu de données aussi restreint et aussi déséquilibré. Le transfer learning constitue donc un prérequis non négociable pour ce type de problème clinique.

3 Biologie des Leucocytes et Complexité Morphologique

Pour comprendre les choix architecturaux effectués, il est indispensable de se pencher sur la biologie des leucocytes. C'est la forme, la texture, la taille et le nombre de lobes du noyau qui fournissent les caractéristiques discriminantes les plus utiles à la classification. Les leucocytes se divisent en trois grandes familles :

- **Granulocytes** : Ils représentent environ 60% des leucocytes et possèdent des granules visibles dans leur cytoplasme. Les neutrophiles voient leur noyau évoluer d'une forme en "U" au stade immature (*Band/BNE*) vers une forme multi-lobée au stade mature (*Segmented/SNE*). Les éosinophiles (EO) possèdent de larges granules et un noyau bilobé. Les basophiles (BA) ont des granules si denses qu'ils masquent souvent le noyau.
- **Monocytes (MO)** : Ce sont les plus grandes cellules (10 à 30 μm). Leur noyau prend souvent la forme d'un rein ou d'un fer à cheval.
- **Lymphocytes (LY, VLY)** : Ils possèdent un noyau rond ou ovale, très sombre, laissant très peu de place au cytoplasme.

Cette évolution continue de la maturation cellulaire rend la création de frontières de classes extrêmement complexe. C’est en particulier le cas pour les paires MY/MMY (myélocytes et métamyélocytes) ou BNE/SNE (neutrophiles en bande et segmentés), dont la séparation est presque arbitraire, même pour un expert humain.

4 Description des Données et Analyse Exploratoire

4.1 Le Jeu de Données

Le jeu de données d’entraînement contient plusieurs milliers d’images RGB de cellules isolées, chacune centrée sur un leucocyte. Les images présentent un fond relativement homogène (coloration de May-Grünwald-Giemsa, MGG), ce qui est favorable à la segmentation mais introduit une variabilité colorimétrique non négligeable selon le lot d’acquisition.

4.2 La Problématique du Déséquilibre Extrême

L’analyse exploratoire du jeu de données révèle une distribution suivant une loi de puissance extrême, reflétant la réalité clinique mais posant un défi majeur pour l’apprentissage profond. La classe SNE (neutrophiles segmentés) domine massivement avec environ 13 000 images, tandis que certaines classes comme les polymphocytes (PLY) ne comptent qu’une dizaine d’images d’entraînement.

La classe SNE représente à elle seule environ 30% des données d’entraînement, tandis que PLY n’en constitue qu’environ 0.5%. Ce déséquilibre est à la fois une contrainte technique et une information biologique : il reflète fidèlement les proportions réelles dans le sang périphérique.

Dans un tel contexte, l’utilisation de l’*accuracy* (exactitude globale) comme métrique d’évaluation est proscrite, car un modèle prédisant aveuglément la classe majoritaire “SNE” obtiendrait un score artificiellement élevé. Le challenge impose donc l’utilisation du **F1-Score Macro**. Le F1-Score de chaque classe c est la moyenne harmonique de la Précision (P) et du Rappel (R) :

$$F1_c = 2 \times \frac{P_c \times R_c}{P_c + R_c} \quad (2)$$

Le F1-Score Macro calcule ensuite la moyenne arithmétique non pondérée des F1-scores de toutes les classes, forçant le modèle à être performant même sur les classes les plus rares :

$$F1_{\text{Macro}} = \frac{1}{N} \sum_{c=1}^N F1_c \quad (3)$$




Figure 1: Distribution globale des 13 classes illustrant la loi de puissance et le déséquilibre extrême du dataset. Les classes minoritaires sont quasi-invisibles à cette échelle.

4.3 Qualité Hétérogène et Rareté Extrême : Le Double Fardeau

Au-delà de la distribution asymétrique, la difficulté majeure de ce projet réside dans l’hétérogénéité qualitative des échantillons. Une inspection visuelle du jeu de données révèle que de nombreuses images souffrent de défauts d’acquisition critiques : flou de mise au point détruisant la texture de la chromatine, bruit numérique sévère (artefacts “poivre et sel”), et aberrations chromatiques liées aux réactifs.

Ce problème qualitatif se heurte frontalement au problème quantitatif. En apprentissage profond, un réseau de neurones a besoin de données massives pour extraire le signal pertinent du bruit. Or, pour des classes comme les polymphocytes (PLY) ou les promyélocytes (PMY) qui ne comptent qu’une dizaine d’images au total, le modèle est condamné à opérer dans un régime de pénurie de données (*low-data regime*). Si parmi ces 15 images, 5 sont floues ou bruitées, le réseau convolutif risque de mémoriser le bruit (le fond, les hématies parasites) comme une caractéristique discriminante de la classe, provoquant un sur-apprentissage fatal. C’est ce double fardeau qui justifie l’abandon des architectures massives au profit de modèles très régularisés.

5 Prétraitements et Augmentation des Données

5.1 Justification du Deep Learning vs. Approche Classique

Historiquement, la classification des leucocytes reposait sur des méthodes séquentielles : seuillage global d’Otsu pour séparer l’avant-plan, suivi d’opérations de morphologie mathématique (érosion, dilatation, ouverture) pour éliminer les artefacts. Des caractéristiques géométriques étaient ensuite extraites pour nourrir un classifieur SVM ou bayésien. La circularité du noyau, par exemple, est définie par :

$$C = \frac{4\pi \cdot A}{P^2} \quad (4)$$

où A est l’aire et P le périmètre du noyau segmenté.

Nous avons rapidement écarté cette approche pour plusieurs raisons. Une part significative de nos images

présente une qualité médiocre, avec un bruit numérique important et un faible contraste : les méthodes basées sur le seuillage d'Otsu s'effondrent sur ces images car le bruit fusionne les contours cellulaires avec le plasma. De plus, les réseaux convolutifs (CNN) extraient des caractéristiques de manière autonome sans dépendre de règles mathématiques rigides, ce qui est indispensable pour modéliser les frontières continues des stades de maturation cellulaire.

5.2 Pré-traitement Adapté à Chaque Approche

Pour l'approche classique (Random Forest), les images ont été converties en niveaux de gris, puis seuillées par la méthode d'Otsu afin d'isoler le noyau cellulaire du cytoplasme. Pour les réseaux convolutifs, la normalisation propre à chaque architecture a été appliquée : ResNet et EfficientNet utilisent des normalisations différentes (respectivement soustraction de la moyenne ImageNet et mise à l'échelle $[0, 1]$), et confondre les deux dégrade significativement les performances.

5.3 Filtre de Netteté Adaptatif

Pour pallier le manque de netteté inhérent aux microscopes optiques et mettre en évidence les granules intracellulaires (cruciaux pour distinguer les éosinophiles des basophiles), nous avons intégré un filtre de netteté `UnsharpMask` dans le pipeline d'augmentation :

```

1 class SharpenImage(object):
2     def __call__(self, img):
3         return img.filter(
4             ImageFilter.UnsharpMask(
5                 radius=2, percent=150))
6
7 # Applique aleatoirement a 50% des images
8 transforms.RandomApply(
9     [SharpenImage()], p=0.5)

```

Listing 1: Filtre de netteté adaptatif via PIL

5.4 Augmentation de Données

Face au faible volume de données pour les classes minoritaires, une stratégie d'augmentation extensive a été mise en place. L'objectif est double : augmenter la diversité apparente des classes rares, et forcer le réseau à apprendre des caractéristiques invariantes aux transformations réelles d'acquisition microscopique. Le tableau 2 récapitule les transformations et leur justification biologique.

Table 2: Pipeline d'augmentation de données

Transformation	Paramètres	Justification
RandomResizedCrop	80–100% de la surface	Variations de distance focale
RandomHFlip / VFlip	$p = 0.5$	Symétrie rotationnelle des cellules
RandomRotation	$[-360, +360]$	Absence d'orientation préférentielle
ColorJitter	$\pm 30\%$ luminosité, contraste, saturation	Variabilité inter-lots de réactifs
SharpenImage	$p = 0.5$ (rayon 2, 150%)	Révélation des granules
Normalize	Moyenne/Std ImageNet	Stabilisation du gradient

Les rotations de 360° sont particulièrement importantes car les cellules au microscope n'ont aucune orientation préférentielle. Le `ColorJitter` simule les variations de teinte dues aux différents lots de réactifs MGG utilisés selon les laboratoires et les dates d'acquisition. En combinaison, ces transformations multiplient effectivement la diversité perçue par le réseau sans introduire de biais sémantique.

6 Ligne de Base Classique : Random Forest

6.1 Sélection des Descripteurs Morphologiques

Notre première expérimentation a consisté à développer une ligne de base d'apprentissage automatique classique basée sur l'extraction manuelle de caractéristiques. Cette approche s'inspire directement de la pratique clinique : les hématologues caractérisent les leucocytes par la forme du noyau, son rapport avec le cytoplasme et ses propriétés tinctoriales. Quatre descripteurs ont été calculés après segmentation par seuillage d'Otsu :

- **Aire** : La surface du noyau en pixels carrés. Discriminant fort entre cellules immatures (blastés, promyélocytes) à grand noyau et cellules matures.
- **Circularité** : Mesure l'irrégularité du contour. Les SNE ont une faible circularité (noyau plurilobé), les LY une circularité proche de 1 (noyau sphérique).
- **Moyenne du canal rouge** : Information cruciale sur l'intensité de la coloration MGG.
- **Variance d'intensité** : Quantifie l'hétérogénéité de la chromatine, indicateur du degré de différenciation.

6.2 Classification par Forêt Aléatoire

Ces descripteurs ont été fournis à un classifieur *Random Forest*. Ce choix a été motivé par sa robustesse face

à la multicolinéarité, sa mesure d'importance des variables, et sa capacité à gérer nativement le déséquilibre des classes via `class_weight='balanced'`, qui pondère automatiquement la contribution de chaque classe à la fonction de coût en inversant les fréquences observées.

6.3 Résultats et Analyse Critique

Cette approche n'a atteint qu'une précision de **16%** en validation, légèrement supérieure à la chance aléatoire ($\approx 7.7\%$ pour un classifieur uniforme). Ce résultat, bien qu'attendu, est instructif : les quatre descripteurs choisis capturent une information trop limitée pour distinguer 13 classes. Des paires comme MY/MMY ou PLY/LY sont quasi-indiscernables sur la seule base de l'aire et de la circularité – ce sont précisément les variations fines de morphologie nucléaire et de texture de la chromatine qui permettent à l'expert de les différencier. Ce résultat a orienté notre stratégie vers des approches capables d'apprendre automatiquement des représentations pertinentes.

7 Première Itération Profonde : MobileNet

Face à l'échec de l'approche classique, la transition vers les réseaux de neurones convolutifs (CNN) s'est imposée naturellement. Plutôt que de commencer par une architecture massive, nous avons opté pour **MobileNet** en transfer learning. Les CNN apprennent hiérarchiquement des représentations de plus en plus abstraites : des bords et textures dans les premières couches, des formes dans les couches intermédiaires, et des concepts sémantiques dans les couches profondes. Ces représentations sont bien plus expressives que des features morphologiques manuelles.

Avec seulement environ 4 millions de paramètres, MobileNet utilise des convolutions *depth-wise separable*, décomposant la convolution standard en deux opérations successives : une convolution *depth-wise* (un filtre par canal d'entrée) suivie d'une convolution *point-wise* (1×1). Cette décomposition réduit le coût de calcul d'un facteur $\frac{1}{N} + \frac{1}{D_K^2}$, où N est le nombre de filtres et D_K la taille du noyau. Pour $D_K = 3$ et $N = 64$, cela représente une réduction de $\sim 87\%$ des opérations.

L'objectif principal était d'obtenir des cycles d'entraînement rapides pour valider nos pipelines d'augmentation. Cette itération rapide a permis d'identifier plusieurs problèmes de configuration (incohérence de taille d'entrée, mauvais `preprocess_input`) avant de passer à des architectures plus coûteuses.

Résultats : Le modèle a atteint une précision plafonnant autour de **35%**. Ce bond de 19 points par rapport au Random Forest prouve la supériorité des représentations apprises. Néanmoins, la capacité de représentation de MobileNet s'est avérée insuffisante pour capturer les textures ultra-fines de la chromatine, justifiant notre montée en charge vers ResNet50.

8 Modèle Principal : ResNet50 et Stratégie en Deux Phases

8.1 Motivation du Choix Architectural

Le passage à ResNet50 répond à une logique de montée en capacité tout en évitant l'écueil du sur-apprentissage. Avec environ 25 millions de paramètres, ResNet50 offre un bon compromis entre expressivité et régularisation implicite. Son architecture à connexions résiduelles (*skip connections*) résout le problème du gradient évanescant, permettant un entraînement stable de réseaux plus profonds.

Comparé à EfficientNetV2S (testé préalablement avec environ 48 millions de paramètres), ResNet50 est deux fois plus petit, ce qui réduit le risque de sur-apprentissage sur un jeu de données de taille modérée. Pour des datasets médicaux de quelques milliers d'images par classe, des architectures légères à moyennes surpassent généralement les très grands modèles en généralisation.

L'idée centrale des réseaux résiduels est d'apprendre une fonction résiduelle $\mathcal{F}(\mathbf{x})$ plutôt que la transformation directe $\mathcal{H}(\mathbf{x})$, de sorte que :

$$\mathcal{H}(\mathbf{x}) = \mathcal{F}(\mathbf{x}) + \mathbf{x} \quad (5)$$

Si la transformation optimale est proche de l'identité (cas fréquent dans les couches profondes), il est plus facile d'apprendre $\mathcal{F}(\mathbf{x}) \approx 0$ que $\mathcal{H}(\mathbf{x}) \approx \mathbf{x}$. Ce mécanisme permet d'entraîner des réseaux de 50 à 152 couches sans dégradation des performances, un avantage considérable pour l'extraction de caractéristiques fines comme les textures de chromatine.

8.2 Architecture de la Tête de Classification

La tête de classification ajoutée sur la base ResNet50 a été volontairement simplifiée. Contrairement à des structures multi-couches complexes, nous avons remplacé la couche finale par une unique couche linéaire :

- `nn.Linear` : Relie les 2048 caractéristiques du pooling global directement aux 13 classes de sortie.

Ce choix se justifie par la volonté de limiter le nombre de paramètres à entraîner sur les classes ultra-minoritaires. L'ajout de couches de Dropout a été testé lors de phases préliminaires mais n'a pas apporté de gain significatif en généralisation, le modèle parvenant à converger de manière stable grâce à l'augmentation de données seule.

8.3 Stratégie d'Entraînement en Deux Phases

L'entraînement suit une stratégie en deux phases distinctes, inspirée des meilleures pratiques en transfer learning médical :

Phase 1 – Entraînement de la tête seule (15 epochs) : La base ResNet50 est entièrement gelée (`trainable=False`). Seule la tête est entraînée avec un taux d'apprentissage de 10^{-4} . Cette phase "chauffe" la tête en lui apprenant à interpréter les features ImageNet pour notre problème, sans perturber les poids pré-entraînés de la base.

Phase 2 – Fine-tuning des dernières couches (50 epochs) : Les dernières couches de la base sont dégelées, avec les couches BatchNormalization maintenues gelées pour éviter la déstabilisation de la normalisation. Le taux d'apprentissage est réduit à 5×10^{-5} et la perte est remplacée par `CategoricalFocalCrossentropy` avec $\gamma = 2$, une variante pondérant davantage les exemples mal classés.

```

1 BATCH_SIZE = 64
2 NUM_EPOCHS = 25
3 LEARNING_RATE = 0.0001
4 IMG_SIZE = 256
5
6 model = models.resnet50(
7     weights=ResNet50_Weights.IMAGENET1K_V2)
8 model.fc = nn.Linear(
9     model.fc.in_features, NUM_CLASSES)
10
11 if torch.cuda.device_count() > 1:
12     model = nn.DataParallel(model)
13 model = model.to(DEVICE)

```

Listing 2: Configuration ResNet50 et multi-GPU

8.4 Environnement Matériel, Stratégie d'Ensemble et K-Fold

L'ensemble de nos expérimentations a été mené sur l'environnement Kaggle, en exploitant l'accélération matérielle de deux GPU NVIDIA T4 via le module `torch.nn.DataParallel`, permettant de paralléliser efficacement les tenseurs sur plusieurs cartes.

Cette puissance de calcul nous a permis de déployer notre stratégie ultime contre la rareté des données : la validation croisée stratifiée à 5 plis (*Stratified 5-Fold Cross-Validation*). En effet, face à l'extrême rareté de certaines classes (ex: 13 images pour les PLY), figer 20% du jeu de données pour un set de validation classique constituait une perte d'information inacceptable.

L'approche K-Fold garantit que 100% des images, y compris les classes ultra-minoritaires, participent à l'entraînement d'au moins 4 modèles sur 5. Lors de l'inférence, au lieu de s'appuyer sur un modèle unique potentiellement biaisé par un tirage chanceux (*lucky split*), nous avons mis en place un vote d'ensemble (*Soft Voting*). Les probabilités *softmax* des 5 experts (les meilleurs modèles de chaque fold) sont moyennées, lisant ainsi les erreurs individuelles et offrant une prédiction finale beaucoup plus robuste.

8.5 Test Time Augmentation (TTA)

Pour l'inférence, une approche de Test Time Augmentation (TTA) a été déployée. Plutôt que de confier la prédiction à une seule image, le réseau évalue l'image originale, sa symétrie horizontale et sa symétrie verticale. Les probabilités d'activation *Softmax* des trois passages sont moyennées. Cette technique lisse les incertitudes du réseau face aux cellules photographiées sous des angles atypiques. Formellement, la prédiction finale $\hat{y}$ pour une image x est obtenue par :

$$\hat{y} = \frac{1}{|T|} \sum_{t \in T} f_{\theta}(t(x)) \quad (6)$$

où $T = \{\text{id}, \text{flip}_H, \text{flip}_V\}$ est l'ensemble des transformations appliquées, et $f_{\theta}(\cdot)$ est la sortie Softmax du réseau.

8.6 Reproductibilité et Fixation des Graines

En apprentissage profond appliqué à l'imagerie médicale, la reproductibilité des expériences est primordiale. Les réseaux de neurones étant sensibles à l'initialisation des poids et à l'ordre de passage des batches, l'ensemble des générateurs de nombres aléatoires a été fixé via une fonction dédiée :

```

1 def set_seed(seed=42):
2     random.seed(seed)
3     os.environ['PYTHONHASHSEED'] = str(seed)
4     np.random.seed(seed)
5     torch.manual_seed(seed)
6     torch.cuda.manual_seed(seed)
7     torch.backends.cudnn.deterministic = True
8
9 set_seed(42)

```

Listing 3: Fixation des generateurs aleatoires

8.7 Résultats et Analyse des Courbes d'Apprentissage

L'entraînement a été mené sur 25 époques. Contrairement aux expérimentations impliquant un sur-échantillonnage, le modèle ResNet50 a montré une convergence saine, atteignant **71% de précision en validation**.

En Phase 1, la précision de validation ($\approx 60\%$) surpasse légèrement la précision d'entraînement ($\approx 50\%$). Ce phénomène, paradoxal en apparence, s'explique par le Dropout actif uniquement en entraînement et par l'augmentation de données qui rend la tâche d'entraînement plus difficile. Cela indique un léger sous-apprentissage en Phase 1, le dropout étant peut-être trop fort pour cette phase de "chauffe". En Phase 2, le fine-tuning permet une progression continue jusqu'à 71%, sans signe d'overfitting marqué (les courbes train et val restent proches).

Comportement du scheduler : Le `ReduceLROnPlateau` a réduit le taux d'apprentissage à deux reprises au cours de la Phase 2, déclenchant à chaque fois un rebond de performance. Ce comportement confirme que le modèle atteignait des plateaux locaux que la réduction du pas permettait de dépasser, sans pour autant diverger. La patience de 3 epochs s'est avérée bien calibrée pour ce jeu de données.

Impact de la TTA : La comparaison des prédictions avec et sans TTA montre un gain de +1.2 points de F1-Macro sur l'ensemble de validation. Ce gain, bien que modeste, est particulièrement marqué sur les classes ayant une grande variabilité d'orientation (BNE, MO), où les symétries permettent de mieux couvrir l'espace des configurations possibles.

9 Expérimentation : Architectures et Gestion du Déséquilibre

9.1 L'Échec de la Sur-paramétrisation : EfficientNet-B4

Forts du succès du ResNet50, l'hypothèse suivante a été posée : augmenter la profondeur du réseau et la résolution spatiale des images permettrait de capturer les détails infimes séparant les stades de maturation proches. L'architecture a été remplacée par un **EfficientNet-B4**, et la résolution des images augmentée à 380×380 pixels.

L'EfficientNet-B4 repose sur le principe de *compound scaling* : la profondeur, la largeur et la résolution du réseau sont augmentées simultanément selon un coefficient composé ϕ , de sorte que :

$$\text{depth} \sim \alpha^\phi, \quad \text{width} \sim \beta^\phi, \quad \text{resolution} \sim \gamma^\phi \quad (7)$$

avec $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$ et $\alpha, \beta, \gamma \geq 1$. Cette mise à l'échelle coordonnée produit un modèle très efficace sur ImageNet, mais se révèle inadaptée à nos contraintes de données.

L'entraînement sur 25 époques a réfuté notre hypothèse : le modèle a plafonné à un F1-Score de validation de **0.7158**, soit une dégradation notable par rapport au ResNet50. Trois facteurs expliquent cet échec. Premièrement, l'EfficientNet-B4 possède une complexité architecturale massive ; sur un jeu de données médical restreint, il a rapidement mémorisé les données d'entraînement (F1 d'entraînement atteignant 0.84). Deuxièmement, l'initialisation avec des poids **IMAGENET1K_V1** (vs. V2 pour ResNet50) rendait le modèle moins apte à extraire des textures cellulaires sans entraînement conséquent. Troisièmement, l'augmentation de la résolution a paradoxalement nui : le réseau a commencé à modéliser le bruit de fond du plasma sanguin.

9.2 L'Impasse Matérielle : ConvNeXt

Nous avons également exploré la famille **ConvNeXt**, une architecture intégrant les avantages des *Vision Transformers* via des convolutions à larges noyaux (7×7). Le modèle ConvNeXt standard a provoqué une saturation immédiate de la mémoire vidéo (VRAM), se soldant par une erreur *Out Of Memory* dès la première époque. La variante **ConvNeXt-Tiny** a permis le lancement de l'apprentissage mais s'est révélée non concluante, peinant à extraire des caractéristiques discriminantes sur nos classes ultra-minoritaires.

L'échec successif d'EfficientNet-B4 et de ConvNeXt valide une hypothèse forte : les architectures de pointe (SOTA), optimisées pour des bases de données gigantesques, souffrent d'un biais inductif inadapté aux jeux de données cliniques restreints et déséquilibrés. Le rapport coût de calcul/bénéfice penche massivement en faveur d'architectures mieux dimensionnées, confirmant le ResNet50 comme modèle optimal.

9.3 L'Échec des Stratégies Classiques de Rééquilibrage

Notre plus grand défi fut le déséquilibre extrême des données. Deux stratégies classiques ont été testées :

1. **Oversampling via WeightedRandomSampler** : Un échantillonneur a été codé pour sélectionner les images inversement proportionnellement à leur fréquence. Les quelques images rares étaient ainsi présentées des milliers de fois. **Résultat** : Un sur-apprentissage total. Le F1-score d'entraînement a dépassé 0.93, tandis que la validation a chuté à 0.6067. Le modèle avait appris le bruit de fond spécifique de ces images plutôt que leur morphologie.

2. **Pondération de la Loss (Class Weights)** : L'application d'un poids majoré pour les erreurs sur les classes minoritaires dans la **CrossEntropyLoss** a provoqué une forte instabilité du gradient, plafonnant le score de validation à 0.599.

Ces deux échecs démontrent que le déséquilibre clinique naturel des données rend les techniques de rééquilibrage agressives totalement contre-productives.

10 Résultats et Analyse des Erreurs

10.1 Comparaison Globale des Approches

Table 3: Comparaison des performances de validation

Modèle	Val. Accuracy	Remarque
Random Forest	$\approx 16\%$	Baseline
MobileNet	$\approx 35\%$	Léger
EfficientNet-B4	$\approx 68\%$	Sur-apprentissage
ResNet50 (final)	$\approx 71\%$	Meilleur résultat

La progression des résultats suit une logique cohérente. Le bond le plus significatif est observé entre le Random Forest (16%) et MobileNet (35%), illustrant la supériorité des représentations apprises sur les features manuelles. La deuxième progression, de MobileNet à ResNet50, s'explique par une architecture plus profonde, une stratégie d'entraînement rigoureuse en deux phases, et une meilleure gestion du déséquilibre.

10.2 Récapitulatif des Hyperparamètres

Le tableau 4 synthétise les configurations finales des deux modèles deep learning les plus représentatifs de notre étude.

Table 4: Hyperparamètres des modèles principaux

Paramètre	ResNet50	EfficientNet-B4
Résolution	256×256	380×380
Batch size	64	32
LR initial	10^{-4}	10^{-4}
Poids ImageNet	V2	V1
Epochs	25	25
Optimizer	Adam	Adam
Scheduler	ReduceLR	ReduceLR
Dropout	0.5 / 0.4	—
TTA	Oui	Non
Val F1-Macro	0.717	0.686

10.3 Analyse par Classe : Forces et Faiblesses

L'analyse détaillée des performances par classe révèle des disparités importantes qui illustrent les enjeux biologiques du problème.

Classes bien reconnues : Les Lymphocytes (LY, $F1 \approx 0.89$) bénéficient d'un noyau très distinct : grand, rond, sombre, occupant presque tout le cytoplasme. Les Neutrophiles Segmentés (SNE, $F1 \approx 0.85$), très représentés, présentent une morphologie multi-lobée caractéristique facilement apprise. Les Éosinophiles (EO, $F1 \approx 0.82$) se distinguent par leurs larges granules bilobés et leur cytoplasme rosé.

Classes intermédiaires : Les Monocytes (MO, $F1 \approx 0.71$) présentent un noyau en fer à cheval reconnaissable, mais leur grande taille crée des confusions avec les blastes (BL). Les Basophiles (BA, $F1 \approx 0.65$) souffrent de la densité de leurs granules qui masquent parfois le noyau, rendant la segmentation implicite difficile.

Classes problématiques : Les paires BNE/SNE ($F1 \approx 0.52$ pour BNE) et MY/MMY ($F1 \approx 0.41$ pour MMY) cristallisent les limites biologiques de la classification : ces stades successifs de la granulopoïèse sont séparés par une frontière continue que même un hématologue expérimenté ne trace qu'avec difficulté. Les classes ultra-rares PLY et PMY (moins de 20 images d'entraînement) obtiennent des F1 proches de zéro, malgré tous nos efforts de régularisation.

10.4 Analyse de la Matrice de Confusion




Figure 2: Matrice de confusion sur l'ensemble de validation illustrant l'absorption des classes rares (PLY) et les hésitations sur la frontière continue de granulopoïèse (BNE/SNE).

La matrice de confusion confirme ces tendances. Les principales confusions observées sont :

- **SNE $\rightarrow$ BNE :** Plus de 300 neutrophiles matures prédits comme immatures, illustrant la difficulté de la frontière de segmentation nucléaire.
- **MMY $\rightarrow$ MY :** Les métamyélocytes (noyau en rein) sont souvent confondus avec les myélocytes

(noyau ovale) en raison de la continuité morphologique de la granulopoïèse.

- **BL $\rightarrow$ MY :** Les blastes (cellules très immatures, grand noyau clair) partagent une silhouette générale avec les myélocytes, trompant les filtres des premières couches convolutives.
- **PLY $\rightarrow$ LY :** Les prolymphocytes sont systématiquement absorbés par la classe lymphocyte, leur morphologie très proche rendant la distinction quasi-impossible sans données supplémentaires.

Ces confusions ne sont pas des artefacts algorithmiques : elles reflètent fidèlement les erreurs que commettraient des stagiaires en hématologie, et parfois même des experts face à des images de mauvaise qualité.

10.5 Analyse Visuelle : Le “Mur des Erreurs”

L'extraction des images mal classifiées permet de comprendre les limites inhérentes à notre approche. Les erreurs du modèle ne sont pas aléatoires, mais s'expliquent par des facteurs biologiques et techniques précis :




Figure 3: Le “Mur des Erreurs” : exemples d'images mal classifiées par le modèle.

- **Frontière continue de différenciation :** Les confusions les plus fréquentes concernent des paires de classes morphologiquement très proches représentant des stades successifs de la granulopoïèse (MY/MMY, BNE/SNE).
- **Artefacts visuels :** Notre réseau convolutif agit comme une boîte noire et analyse l'image entière. Certaines images présentent un bruit numérique extrême (“poivre et sel”) détruisant la texture de la chromatine.
- **Superposition cellulaire :** Dans de nombreux cas d'erreur, des globules rouges ou des amas de plaquettes se superposent au cytoplasme du leucocyte. Le réseau intègre alors ces parasites dans son inférence, faussant la prédiction finale.

Ces exemples visuels démontrent que l'amélioration future ne proviendra pas d'un modèle plus lourd, mais d'un pré-traitement capable d'isoler la cellule de son environnement.

11 Gestion du Déséquilibre : Bilan et Stratégies

La gestion du déséquilibre de classes a été au cœur de notre démarche. Nous synthétisons ici les différentes approches testées et leurs effets observés.

Les **class weights** calculés avec **sklearn** pondèrent chaque classe inversement à sa fréquence dans la fonction de perte. Si le réseau se trompe sur une image SNE, il sera moins pénalisé que s'il se trompe sur une image PLY. Cette approche, bien qu'intuitive, a provoqué une instabilité du gradient lorsque les poids sont trop extrêmes (rapport de 1 à 10 000 entre SNE et PLY).

La **data augmentation**, notamment les rotations, zooms et variations de luminosité sur les classes minoritaires, constitue notre stratégie la plus efficace. Elle augmente artificiellement la diversité des classes rares sans risquer le sur-apprentissage sur un nombre fixe d'images.

Le **dropout** a été exploré comme technique de régularisation pour éviter la co-adaptation des neurones. Cependant, dans le contexte spécifique de ce challenge, son utilisation n'a pas donné de résultats probants. Les tests ont montré que le dropout avait tendance à ralentir la convergence sur les classes rares sans pour autant améliorer le F1-Score en validation. Nous avons donc choisi de le retirer du pipeline final au profit d'une augmentation de données plus agressive.

L'**early stopping** permet de stopper l'apprentissage après plusieurs epochs sans amélioration de la validation. Il constitue un garde-fou efficace contre le sur-apprentissage progressif observé sur les architectures plus lourdes.

En définitive, la combinaison data augmentation + dropout + early stopping s'est avérée bien plus efficace que les approches de rééquilibrage agressives (oversampling, class weights élevés).

Le tableau 5 synthétise l'impact de chaque stratégie testée sur les métriques d'entraînement et de validation, illustrant clairement le paradoxe du sur-rééquilibrage.

Table 5: Impact des stratégies de gestion du déséquilibre

Stratégie	F1 Train	F1 Val
Aucune correction	0.74	0.71
Class Weights	0.80	0.60
Oversampling (WRS)	0.93	0.61
Data Augmentation seul	0.76	0.72
Essais avec Dropout	0.71	0.65

Ce tableau illustre un phénomène clé : plus une stratégie tente de corriger agressivement le déséquilibre au niveau de la loss ou de l'échantillonnage, plus l'écart train/val se creuse. Seule l'augmentation de données, qui agit sur la diversité plutôt que sur la fréquence, maintient une généralisation saine.

12 Post-traitement et Soumission

12.1 Génération des Prédictions

Pour l'inférence sur le jeu de test, le meilleur modèle sauvegardé (checkpoint sur **val_accuracy**) a été

rechargé. Les images de test ont été pré-traitées de manière identique à l'entraînement (même taille d'entrée, même normalisation), un point critique pour éviter un biais de distribution entre entraînement et inférence. Le mapping entre indices de sortie du réseau et noms de classes a été explicitement sauvegardé dans un fichier JSON au moment de la construction des générateurs, garantissant la cohérence même en cas de rechargement indépendant.

```
1 import json
2
3 # Sauvegarde du mapping au moment de l'
  entraînement
4 class_to_idx = train_dataset.class_to_idx
5 idx_to_class = {v: k for k, v in class_to_idx.
  items()}
6 with open("class_mapping.json", "w") as f:
7     json.dump(idx_to_class, f)
8
9 # Inférence avec TTA
10 model.eval()
11 with torch.no_grad():
12     for img_path in test_images:
13         img = load_image(img_path)
14         flipped_h = transforms.functional.
15             hflip(img)
16         flipped_v = transforms.functional.
17             vflip(img)
18         probs = (softmax(model(img)) +
19                 softmax(model(flipped_h)) +
20                 softmax(model(flipped_v))) /
21                 3
22         pred = idx_to_class[probs.argmax().
23             item()]
```

Listing 4: Sauvegarde du mapping classes et inférence TTA

12.2 Analyse de la Distribution des Prédictions

L'analyse de la distribution des labels prédits sur le jeu de test constitue une validation de cohérence : si la distribution des prédictions s'écarte trop de la distribution attendue biologiquement (SNE devrait être le plus fréquent, PLY le plus rare), cela signale un problème de calibration du modèle. Cette vérification a été systématiquement effectuée après chaque soumission.

La distribution observée sur nos prédictions finales est globalement cohérente avec les proportions biologiques : SNE représente la classe majoritaire des prédictions, suivie des LY et MO. Les classes extrêmement rares (PLY, PMY) sont prédites avec parcimonie, signe que le modèle n'est pas dégénéré vers la prédiction aveugle de la classe majoritaire. Cette cohérence biologique est un indicateur indirect de la qualité de la calibration du modèle.

12.3 Gestion du Mapping Kaggle

Un point de vigilance spécifique au challenge Kaggle concerne la cohérence entre les noms de classes dans le fichier de soumission et les labels attendus par la plateforme. Une incohérence de nommage (majuscules/minuscules, tirets vs. underscores) peut invalider une soumission entière malgré des prédictions correctes. Nous avons systématiquement vérifié la correspondance exacte entre notre

fichier de mapping JSON et le fichier d'exemple fourni dans les données du challenge.

13 Perspectives d'Amélioration

Notre analyse des échecs définit clairement la voie pour les travaux futurs.

Segmentation explicite : Pour dépasser notre plafond de 71%, le pipeline devra intégrer une segmentation explicite en amont de la classification. L'utilisation d'architectures dédiées (U-Net, Mask R-CNN) permettrait de masquer complètement le plasma et les hématies parasites. En ne fournissant au ResNet50 qu'un noyau et cytoplasme parfaitement isolés, le réseau pourrait dédier 100% de ses filtres à l'analyse fine de la maturation cellulaire.

Architecture : L'utilisation d'EfficientNetV2B1 (avec la correction du `preprocess_input` spécifique et la cohérence de taille d'entrée) pourrait offrir de meilleures performances grâce à ses blocs Fused-MBConv optimisés pour les petites images.

Données synthétiques : La génération d'images synthétiques via des GAN conditionnels pour les classes sous-représentées (PLY, PMY) pourrait réduire le déséquilibre de manière plus robuste que les class weights seuls.

Ensemble de modèles : La combinaison par vote mou des sorties de plusieurs modèles (ResNet50 + EfficientNetV2B1) exploite la diversité architecturale pour réduire la variance des prédictions, une technique standard dans les compétitions Kaggle.

Scheduler avancé : Un cosine annealing with warm restarts permettrait une exploration plus fine de l'espace des paramètres en phase 2, potentiellement en sortant de plateaux temporaires. Comparé au `ReduceLROnPlateau` utilisé dans notre implémentation finale, cette stratégie offre une descente de gradient plus régulière sur l'ensemble de l'entraînement.

Interprétabilité : L'utilisation de techniques de visualisation comme Grad-CAM (Gradient-weighted Class Activation Mapping) permettrait de vérifier que le réseau focalise bien son attention sur le noyau cellulaire plutôt que sur le fond ou les hématies parasites. Cette validation est particulièrement précieuse dans un contexte médical où la confiance dans les prédictions est aussi importante que leur précision.

Apprentissage auto-supervisé : Des approches comme SimCLR ou DINO, qui pré-entraînent un encodeur sur les images sans labels, pourraient extraire des représentations spécifiques aux données microscopiques avant le fine-tuning supervisé, comblant l'écart entre les features ImageNet et les textures cellulaires.

14 Conclusion

Ce projet a exploré l'application de l'apprentissage profond pour la classification de 13 sous-types de leucocytes sanguins. Partant d'une ligne de base Random Forest (16%), nous avons progressé de manière itérative jusqu'à 71% de précision avec ResNet50 en transfer learning, soit un gain de plus de 50 points de pourcentage.

Notre conclusion principale est paradoxale : dans le domaine de l'imagerie médicale hématologique, **la sophistication algorithmique peut se révéler destructrice**. Le déséquilibre clinique naturel des données rend les techniques de sur-échantillonnage totalement inefficaces en provoquant un sur-apprentissage immédiat. Les architectures de pointe (EfficientNet-B4, ConvNeXt), optimisées pour ImageNet, souffrent d'un biais inductif inadapté aux jeux de données cliniques restreints.

Les erreurs résiduelles sont biologiquement interprétables : les confusions concernent principalement des paires de classes représentant des stades successifs de différenciation cellulaire, pour lesquelles même l'expertise humaine nécessite parfois des informations contextuelles supplémentaires. Cela fixe une limite supérieure naturelle à ce qui est réalisable à partir de l'image seule.

Bilan méthodologique : La démarche adoptée montre que la complexité n'est pas toujours synonyme de performance. L'abandon de techniques comme le Dropout ou l'oversampling au profit d'un transfert learning pur sur ResNet50 avec une tête linéaire simple a permis d'obtenir un modèle plus robuste et plus facile à calibrer.

Impact clinique potentiel : Un système atteignant 71% de F1-Macro sur 13 classes aussi déséquilibrées représente déjà une aide significative pour le triage automatique des frottis sanguins. En pratique, un tel système ne remplacerait pas l'hématologue, mais permettrait de pré-trier les cas évidents (LY, SNE), libérant le spécialiste pour se concentrer sur les cas ambigus (BNE/SNE, MY/MMY) ou les classes rares à fort enjeu clinique (blastés, promyélocytes). L'intégration d'une étape de segmentation cellulaire explicite (U-Net, SAM) en amont reste la priorité absolue pour franchir le seuil des 75% et envisager un déploiement clinique réel.

References

- [1] K. Al-Dulaimi *et al.*, "Classification of White Blood Cell Types from Microscope Images: Techniques and Challenges", *Microscopy Book Series*, Formatex, pp. 17–25, 2018.
- [2] A. Gautam et H. Bhadauria, "Classification of White Blood Cells Based on Morphological Features", *ICACCI*, IEEE, pp. 2363–2367, 2014.
- [3] K. He *et al.*, "Deep Residual Learning for Image Recognition", *CVPR*, IEEE, pp. 770–778, 2016.
- [4] M. Tan et Q. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks", *ICML*, 2019.
- [5] Z. Liu *et al.*, "A ConvNet for the 2020s", *CVPR*, 2022.
- [6] T.-Y. Lin *et al.*, "Focal Loss for Dense Object Detection", *ICCV*, IEEE, pp. 2980–2988, 2017.
- [7] Challenge IMA205 – Télécom Paris, *Classification de Globules Blancs par Apprentissage Automatique et Apprentissage Profond*, Rapport académique, 2026.